

제조 데이터 분석 및 수율 최적화

서울시립대학교 전자전기컴퓨터공학부
엄대호 교수

INSTRUCTOR

강사 소개

임대호

서울시립대학교
전자전기컴퓨터공학부

조교수

수상

강의우수교수상 (2025)

서울시립대학교

학력

공학박사 · 전기·정보공학

서울대학교 (서울, 대한민국)

2019.03 – 2024.08

공학사 · 전기전자전파공학

고려대학교 (서울, 대한민국)

2013.03 – 2019.02

경력

조교수

서울시립대학교 전자전기컴퓨터공학부

2025.09 – 현재

스태프 엔지니어

삼성전자 AI센터 공정/설비 AI Lab

2025.01 – 2025.08

스태프 엔지니어

SAIT(삼성종합기술원) Machine Learning Technical Unit

2024.09 – 2024.12

주요 강의

SK그룹 ML Engineer 과정 · 현대자동차 AI Boosting Camp 과정 · 삼성전자 AI전문가 과정

언론 보도

[중앙일보] 서울시립대 임대호 교수 연구팀, 세계 최고 권위의 머신러닝 학회 'ICML 2026' 논문 채택

[한겨레] 서울시립대 임대호 교수 연구팀, 인공지능 분야 세계 최고 권위 'CVPR 2026' 논문 채택

문제 정의

- 제조 현장에서 우리는 무엇을 알고 싶은가?
 - 지금 이 공정은 정상 범위 안에 있는가?
 - 어떤 공정 조건이 불량과 크게 연관되어 있는가?
 - 공정을 어떻게 개선해야 불량을 줄일 수 있을까?
- 문제 정의
 - 입력:
제조 공정에서 측정되는 다수의 센서 데이터
 - 원하는 출력(목표):
불량 여부 (정상 / 불량), 불량 위험도 또는 품질 지표, 특정 공정 조건의 임계 값

실제 제조 데이터의 특성

- 제조 데이터에서 흔히 발생하는 문제

- 결측값:

- 측정 비용 문제, 센서 고장, 통신 오류, 특정 공정 구간에서만 측정 등의 이유로 빈번히 발생

- 의미 없는 센서:

- 항상 같은 값을 가지는 센서

- 노이즈와 이상치:

- 순간적인 공정 이상, 센서 드리프트

전처리의 중요성

- 전처리는 단순한 준비 과정이 아니다
 - 결측치는 AI 모델의 사용을 막는다
 - 상수/저분산 센서, 노이즈, 이상치는 분석을 방해하고 잘못된 인사이트를 만들 수 있다
 - 범주형 데이터(e.g., 제조 공장: 천안 or 충주 or 청주)를 숫자로 변환하는 과정도 필요
- 전처리는 AI 기반 문제해결을 위한 핵심 과정

결측값 (Missing Values)

- 결측값이란?
 - 데이터가 기록되지 않았거나 수집되지 않은 상태
- 제조 현장에서 발생하는 이유
 - 센서 고장
 - 통신 오류
 - 측정 비용 문제
 - 특정 공정에서만 측정

Time	Temperature
09:00	32.1
09:01	31.9
09:02	NA
09:03	NA
09:04	32.0

Column 0	age	years_seniority	income	parking_space	attending_party	entree	pets	emergency_contact
Tony	48	27		1	5	shrimp		Pepper
Donald	67	25	86	10	2	beef		Jane
Henry	69	21	95	6	1	chicken	62	Janet
Janet	62	21	110	3	1	beef		Henry
Nick		17		4				
Bruce	37	14	63		1	veggie		NA
Steve	83		77	7	1	chicken		n/a
Clint	27	9	118	9		shrimp	3	None
Wanda	19	7	52	2	2	shrimp		empty
Natasha	26	4	162	5	3			-
Carol		3	127	11	1	veggie	1	""
Mandy	44	2	68	8	1	chicken		null

왜 결측값이 문제가 될까?

1. 데이터의 실제 특성을 왜곡할 수 있음
2. 패턴 분석이 어려워짐
정상 데이터: 40 → 42 → 45 → 48 → 50
결측 발생: 40 → NA → NA → 48 → 50
3. 머신러닝 모델이 학습할 수 없음
4. 중요한 이상 현상을 놓칠 수 있음

상수 센서

- 상수 센서란?
 - 시간이 지나도 값이 거의 변하지 않는 센서
- 왜 발생할까?
 - 센서 고장, 사용되지 않는 센서, 설정 오류
- 왜 문제가 될까?
 - 공정 변화를 설명하지 못함
 - 저장 공간 및 계산 자원 낭비
 - 모델 성능 저하 가능


Time	Temperature
09:00	32.1
09:01	31.9
09:02	32.5
09:03	31.7
09:04	32.0

Time	Sensor A
09:00	100
09:01	100
09:02	100
09:03	100
09:04	100

이상치 (Outliers)

- 이상치란?
 - 다른 데이터와 비교했을 때 현저히 크거나 작은 값
- 왜 발생할까?
 - 센서 오류, 데이터 입력 오류, 실제 공정 이상
- 왜 문제가 될까?
 - 평균을 왜곡함
 - 모델 성능 저하

Time	Temperature
09:00	32.1
09:01	31.9
09:02	32.5
09:03	287.8
09:04	32.0



왜 데이터 분석이 필요할까?

- 많은 제조 현장에서는 데이터가 매일 생성된
 - 수백 개의 센서
 - 수천 개의 공정 변수
 - 수만 건의 생산 데이터
- 예시: 설비 1대
 - 온도 센서
 - 압력 센서
 - 진동 센서
 - 전류 센서
- 데이터는 많지만, 정보는 자동으로 얻어지지 않는다

데이터는 있지만 정보는 없다

- 데이터(Data)와 정보(Information)의 차이
- 데이터: 숫자들의 집합
 - e.g., 35.2, 35.7, 36.1, 36.2, 36.8
- 정보: 의미를 가진 해석 결과
 - e.g., 온도가 지속적으로 상승하고 있음
- 인사이트: 실제 의사결정에 활용 가능
 - e.g., 온도 상승이 불량 증가와 관련 있음
- 데이터 분석의 역할
 - 데이터 → 정보 → 인사이트

품질 문제를 조기에 발견할 수 있다

- 기존 방식
 - 제품 생산 → 검사 → 불량 발견 → 원인 조사
 - 이미 불량이 발생한 후에 대응
- 데이터 분석 활용
 - 공정 데이터 분석 → 이상 징후 발견 → 불량 예측 → 사전 대응
 - e.g., 온도 상승 → 불량률 증가 → 설비 점검 실시 → 불량 감소
- 사후 대응에서 사전 예방으로 전환

설비 고장을 미리 예측할 수 있다

- 설비 고장의 문제
 - 갑작스러운 설비 정지 → 생산 중단 → 납기 지연 → 비용 증가
- 데이터 분석 활용
 - 진동/전류/온도 데이터 분석 → 고장 징후 탐지 → 사전 정비
 - e.g., 베어링 진동 증가 → 2주 후 설비 고장 발생 → 데이터 분석을 통해 조기 발견 가능
- 예지보전(설비 이상을 상태 감시에 의하여 예지하고, 그 정보에 기인하여 행하는 보전)의 핵심은 데이터 분석이다

생산 공정을 최적화할 수 있다

- 같은 제품이라도 공정 조건에 따라 생산량, 품질, 에너지 사용량이 달라질 수 있음

온도	불량률
170℃	5.1%
180℃	2.8%
190℃	6.3%

- 데이터 분석 결과 → 180 °C가 최적 조건
- 최적의 공정 조건을 데이터로 찾을 수 있다

제조 현장의 데이터 분석 활용 사례

- 품질 예측
 - 공정 데이터 → 불량 예측
- 이상 탐지
 - 센서 데이터 → 이상 징후 탐지
- 예지 보전
 - 설비 데이터 → 고장 예측
- 공정 최적화
 - 공정 변수 → 최적 조건 탐색

제조 현장의 데이터 분석 활용 사례

GE Aviation – 항공기 엔진 예지보전

- 문제: 과거에는 엔진이 고장난 후에 정비 → 갑작스러운 운항 중단 → 막대한 비용 발생
- 데이터 분석 활용
 - 수천 개 센서로 온도, 압력, 진동 데이터 수집 → 고장 패턴 분석 → 고장 발생 전 정비
- 결과
 - 정비 비용 감소
 - 비계획 정지 감소
 - 안전성 향상

제조 현장의 데이터 분석 활용 사례

Siemens – 생산라인 품질 분석

- 문제: 제품 불량률이 발생하지만 원인을 찾기 어려움
- 데이터 분석 활용
 - 공정 데이터(온도, 압력, 생산 속도) 분석 → 불량 발생 조건 발견
- 결과
 - 불량률 감소
 - 생산 효율 향상

제조 현장의 데이터 분석 활용 사례

Toyota – 생산 공정 최적화

- 문제: 동일한 제품 내에서 품질 편차 발생
- 데이터 분석 활용
 - 생산 이력 분석 → 공정 조건과 품질 관계 분석 → 최적 공정 조건 도출
- 결과
 - 품질 안정화
 - 생산성 향상

제조 현장의 데이터 분석 활용 사례

삼성전자나 TSMC 같은 반도체 기업

- 하루에도 수백 GB~TB 수준의 공정 데이터를 생성
- 데이터 분석 활용
 - 이상 공정 탐지
 - 수율(Yield) 분석
 - 장비 상태 분석

제조 혁신은 AI 자체가 아니라, 데이터를 수집하고 분석하여 의사결정에 활용하는 것에서 시작

제조 데이터는 어떻게 저장될까?

- 제조 현장의 데이터
 - 센서와 설비에서는 지속적으로 데이터가 생성된다

- 예시:

시간	온도	압력	진동
09:00	35.2	1.5	0.02
09:01	35.3	1.6	0.03
09:02	35.5	1.7	0.02

- 일반적인 저장 형태
 - CSV
 - Excel
- 제조 데이터는 대부분 표 형태로 저장된다

행(Row)과 열(Column)

시간	온도	압력	진동
09:00	35.2	1.5	0.02
09:01	35.3	1.6	0.03
09:02	35.5	1.7	0.02

- 행: 하나의 관측값
 - e.g., 09:00의 공정 상태
- 열: 하나의 변수(Variable)
 - e.g., 온도, 압력, 진동

제조 데이터의 변수들

시간	온도	압력	전류	품질
09:00	35.2	1.5	0.02	정상
09:01	35.3	1.6	0.03	정상
09:02	35.5	1.7	0.02	불량

- 공정 변수(Process Variables)
 - 온도, 압력, 속도, 전류
- 품질 변수(Quality Variables)
 - 정상/불량, 제품 치수, 강도
- 공정 변수는 원인, 품질 변수는 결과인 경우가 많다

데이터 타입 이해

시간	온도	압력	전류	품질
09:00	35.2	1.5	0.02	정상
09:01	35.3	1.6	0.03	정상
09:02	35.5	1.7	0.02	불량

- 숫자형 데이터
 - e.g., 온도, 압력, 속도
- 범주형 데이터
 - e.g., 정상, 불량
- 날짜/시간 데이터
 - e.g., 2025-05-01 09:00

시계열(Time-Series) 데이터

시간	온도	압력	전류	품질
09:00	35.2	1.5	0.02	정상
09:01	35.3	1.6	0.03	정상
09:02	35.5	1.7	0.02	불량

- 많은 제조 데이터는 시계열 데이터
 - 시간 순서가 존재
- 현재 상태는 과거 상태의 영향 받는다



Feature와 Target

- Feature (입력 변수)
 - 온도
 - 압력
 - 전류
- Target (예측 대상)
 - 불량 여부
 - 생산량
 - 설비 고장
- Feature를 이용하여 Target을 설명하거나 예측한다

왜 통계가 필요할까

제조 데이터의 문제

- 하루 동안 측정된 온도: 35.1, 34.8, 35.4, 35.2, 34.9, 35.0, ...
- 수천 개의 숫자가 존재
- 질문: 이 데이터를 한 문장으로 요약할 수 있을까?
- 해결방법: 통계량(Statistics)
 - 데이터를 몇 개의 숫자로 요약
 - e.g., 평균, 중앙값, 최빈값, 최소값, 최대값, 범위, 분산, 표준편차

평균(Mean)

- 데이터의 대표값

- 공식

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$$

- 예시


- 온도 데이터: 30, 35, 40, 45, 50

- 평균: $(30+35+40+45+50)/5 = 40$

- 전반적인 수준을 나타냄

평균의 한계

- 데이터 A: 38, 39, 40, 41, 32
 - 평균 = 40
- 데이터 B: 10, 20, 40, 60, 70
 - 평균 = 40
- 평균은 동일하지만 데이터 특성은 완전히 다름
- 평균은 중심만 알려줄 뿐, 데이터의 퍼짐 정도는 알 수 없다



분산(Variance)


- 데이터가 평균으로부터 얼마나 퍼져 있는지를 나타내는 지표

- 공식

$$\text{Var}(X) = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$$

- 직관적 의미

- 분산이 작음 $\rightarrow$ 데이터가 평균 주변에 모여 있음
- 분산이 큼 $\rightarrow$ 데이터가 넓게 퍼져 있음



표준편차(Standard Deviation)

- 데이터가 평균으로부터 얼마나 퍼져 있는지를 나타내는 지표
- 분산의 문제점: 분산은 차이를 제곱해서 계산
- 예시
 - 온도 단위 : °C
 - 분산 단위 : °C²
- 직관적으로 이해하기 어려움
- 해결 방법: 분산에 제곱근을 적용

$$\text{표준편차} = \sqrt{\text{분산}}$$

- 공식

$$\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2}$$

평균, 분산, 표준편차 비교

통계량	의미
평균	데이터의 중심
분산	데이터의 퍼짐 정도
표준편차	평균으로부터의 평균적인 거리

- 평균 → 공정 수준
- 표준편차 → 공정 안정성
- 평균은 어디 근처에 있는가를 알려주고, 표준편차는 얼마나 흔들리는가를 알려준다

데이터 전처리란?

- 데이터 전처리(Data Preprocessing): 원시 데이터를 분석 가능한 형태로 변환하는 과정
- 제조 현장의 실제 데이터:

SECOM Data Head:																					
	0	1	2	3	4	5	6	7	8	9	...	580	581	582	583	584	585	586	587	588	589
0	3030.93	2564.00	2187.7333	1411.1265	1.3602	100.0	97.6133	0.1242	1.5005	0.0162	...	NaN	NaN	0.5005	0.0118	0.0035	2.3630	NaN	NaN	NaN	NaN
1	3095.78	2465.14	2230.4222	1463.6606	0.8294	100.0	102.3433	0.1247	1.4966	-0.0005	...	0.0060	208.2045	0.5019	0.0223	0.0055	4.4447	0.0096	0.0201	0.0060	208.2045
2	2932.61	2559.94	2186.4111	1698.0172	1.5102	100.0	95.4878	0.1241	1.4436	0.0041	...	0.0148	82.8602	0.4958	0.0157	0.0039	3.1745	0.0584	0.0484	0.0148	82.8602
3	2988.72	2479.90	2199.0333	909.7926	1.3204	100.0	104.2367	0.1217	1.4882	-0.0124	...	0.0044	73.8432	0.4990	0.0103	0.0025	2.0544	0.0202	0.0149	0.0044	73.8432
4	3032.24	2502.87	2233.3667	1326.5200	1.5334	100.0	100.3967	0.1235	1.5031	-0.0031	...	NaN	NaN	0.4800	0.4766	0.1045	99.3032	0.0202	0.0149	0.0044	73.8432
5 rows × 590 columns																					

- 바로 분석 가능할까?
- 먼저 해야 할 일: 결측치 처리, 이상치 처리, 데이터 정제

왜 전처리가 필요할까?

- 실제 제조 데이터는
 - 누락됨
 - 잘못 측정됨
 - 노이즈가 존재함
 - 불필요한 변수가 존재함
- 예시
 - 온도 데이터: 35, 36, 37, 999, 38, NA
 - 이 데이터를 그대로 분석하면 잘못된 결과 가능
- 데이터 품질이 분석 결과를 결정한다

Garbage In, Garbage Out

- GIGO 원칙
 - Garbage In → Garbage Out
- 의미
 - 잘못된 데이터 → 잘못된 분석 결과
- 예시
 - 센서 오류: 35, 36, 999, 37, 38
 - 평균 계산: 289
 - 실제 공정 상태를 전혀 반영하지 못함
- 좋은 모델보다 좋은 데이터가 먼저이다

제조 데이터에서 흔히 발생하는 문제

- 결측값
 - 센서 고장, 통신 오류, 측정 실패
- 의미 없는 센서
 - 항상 같은 값
- 노이즈
 - 작은 측정 오차
- 이상치
 - 비정상적으로 크거나 작은 값
- 제조 데이터는 대부분 전처리가 필요하다

데이터 전처리 과정

- 일반적인 분석 절차
 - 데이터 수집 → 데이터 전처리 → 데이터 분석 → 의사결정
- 전처리 단계
 - 결측치 처리
 - 이상치 처리
 - 변수 선택
 - 데이터 정제
- 전처리는 데이터 분석의 필수 단계이다

데이터 전처리 예시

온도	→	온도
35		35
36		36
NA		36.5
37		37
500		제거

- 신뢰할 수 있는 데이터 확보
 - 데이터 분석을 위한 머신러닝 모델이 입력으로 받아들일 수 있는 형태로 바꿈
 - 전처리 후 결과가 실제 공정을 더 잘 반영
- 전처리는 데이터를 깨끗하게 만드는 과정

결측치 처리 전략

- 결측치 → 통계량 왜곡, 패턴 분석 어려움, AI 모델 학습 불가, 이상 현상 분석 실패
- 결측치는 단순한 빈칸이 아니라 정보의 손실
- 가장 먼저 해야 할 일
 - 결측치의 양을 확인

변수	결측 비율
온도	1%
압력	2%
진동	45%

- 결측치 처리 전에 먼저 현황을 파악해야 한다

결측치 처리 방법 1: 행 삭제

- 결측이 포함된 행 제거

온도	압력
35	1.5
NA	1.6
37	1.7



온도	압력
35	1.5
37	1.7

- 장점
 - 매우 간단
 - 구현 쉬움
- 단점
 - 데이터 손실 발생
- 사용 시점: 결측 비율이 매우 낮을 때

결측치 처리 방법 2: 평균 대체

- 결측값을 평균으로 대체
- 예시

온도	압력
40	1.2
42	NA
NA	1.8
44	6.0



온도	압력
40	1.2
42	3.0
42	1.8
44	6.0

- 빠르고 구현이 쉽다

결측치 처리 방법 3: 중앙값 대체

- 결측값을 중앙값으로 대체
- 예시

온도	압력
40	1.2
42	NA
NA	1.8
44	6.0



온도	압력
40	1.2
42	1.8
42	1.8
44	6.0


- 이상치에 강인하다.

결측치 처리 방법 4: 선형 보간

- 제조 시계열 데이터에서 자주 사용

lot_id	cell_id	param_id	timestamp_id	measure_val
1	1	1	1	10.235654250405200
1	1	1	2	6.420217266962500
1	1	1	3	
1	1	1	4	16.278196867069900
1	1	1	5	11.043981185063200
1	1	1	6	8.173617377009170
1	1	1	7	
1	1	1	8	9.405176524991060
1	1	1	9	8.048817274030900

⋮ ⋮ ⋮ ⋮ ⋮




결측치 처리 방법 5: kNN 대치

- 비슷한 데이터 활용
- 결측이 포함된 각 데이터와 비슷한 k개의 공정 상태를 찾음
- k개의 공정 상태로 결측값 추정
- 장점
 - 단순 평균 대치보다 더 사실적인 대치가 가능하다
- 단점
 - 데이터 크기가 클 경우 계산량이 커질 수 있다

이상치

- 이상치(Outlier)란?
 - 다른 데이터와 비교했을 때 현저히 크거나 작은 값
- 예시
 - 온도: 48, 49, 50, 51, 52, 300
- 질문: 300은 정상 데이터일까?
- 센서 오류일 수도 있고 실제 공정 이상일 수도 있음



왜 이상치가 문제일까?

- 실제 공정 상태를 제대로 반영하지 못하여 데이터 분석을 방해함
- 예시: 평균 왜곡
 - 정상 데이터: 48, 49, 50, 51, 52
→ 평균 = 50
 - 이상치 포함: 48, 49, 50, 51, 52, 300
→ 평균 = 92
- 머신러닝 성능 저하
 - 회귀 모델, 통계 분석, 예측 모델에 큰 영향을 줄 수 있음

이상치 제거 전에 확인해야 할 것

- Case 1. 센서 오류

50 → 51 → 300 → 50 → 49

- 제거 후보

- Case 2. 실제 공정 이상





50 → 60 → 80 → 120

- 중요한 정보

- 먼저 원인을 확인해야 함
- 무조건 제거가 아닌 원인 분석 후 판단
- 이상치 탐지는 기술 문제이지만, 제거는 도메인 지식이 필요


이상치 탐지 방법 1: 시각화

- 산점도



이상치 탐지 방법 2: IQR



- IQR (Interquartile Range)
- 데이터의 중앙 50% 범위
- 이상치 판단 기준: $Q1 - 1.5 \times IQR$ 보다 작거나 $Q3 + 1.5 \times IQR$ 보다 크면 이상치



- IQR은 가장 널리 사용되는 이상치 탐지 방법이다

이상치 탐지 방법 2: IQR

Boxplots of each feature showing outliers



이상치 제거 방법

- 방법 1: 행 삭제

온도		온도
35		35
36		36
500	→	37
37		38
38		

- 간단하지만 정보 손실이 생긴다

이상치 제거 방법

- 방법 2: 값 대체

온도
35
36
500
37
38



온도
35
36
36
37
38

- 평균값, 중앙값, 최근 값 등으로 대체
- 장점: 데이터 수 유지
- 단점: 실제 정보 손실 가능

이상치 처리 절차

- 이상치 탐지
 - 활용 방법: 시각화, Box Plot
- 원인 분석
 - 이 값은 오류인가, 중요한 신호인가?
- 처리 방법 결정
 - 원인에 따라 처리 방법 선택
 - 센서 오류 → 삭제, 평균/중앙값 대체
- 실제 공정 이상
 - 유지
 - 별도 분석 수행
- 결과 확인
 - 처리 전후 비교

데이터 탐색

- 데이터 탐색 (Exploratory Data Analysis)
 - 데이터를 다양한 관점에서 살펴보는 과정
 - 데이터의 특징과 구조 파악
 - 숨겨진 패턴 발견
 - 분석 방향 결정
- 데이터 분석 과정
 - 데이터 수집
 - 데이터 전처리
 - 데이터 탐색
 - 인사이트 도출
 - 의사결정

데이터 탐색이 필요한 이유

- 제조 데이터의 특징
 - 데이터 양이 많음
 - 변수 수가 많음
 - 복잡한 관계 존재
 - 이상 현상 포함 가능
- 데이터 탐색의 목적
 - 데이터 이해
 - 이상 현상 발견
 - 변수 관계 분석
 - 문제 원인 파악

데이터 분포 확인

- 분포(Distribution)란?


- 데이터가 어떻게 퍼져 있는지 나타냄
- 데이터의 전체적인 특성 파악 가능

- 확인할 수 있는 정보

- 평균 수준
- 최소값 / 최대값
- 데이터 범위
- 이상치 존재 여부

- 활용 그래프

- 히스토그램
- 박스플롯(Box Plot)



KBS NEWS

분야별 ▾ 시사·다큐 ▾ TV 뉴스 ▾ 뉴스코너 ▾ 지역뉴스

뉴스9 취재K 글로벌K 스포츠 **크랩** 케이아 #코로나19 3차 대유행 날씨·재난 **재보** ON AIR

확진자 현황

시도별 추이

연령별 분석

선별진료소

거리두기 단계





* 치명률 = 확진자 중 사망자의 비율

* 각 연령대별 구간에 미우스 커서를 갖다 대시면, 좌측에서 연령대별 확진자 비율을, 우측에서 연령대별 사망자 비율을 확인할 수 있습니다.

업데이트: 2021-01-28 14:15 출처: 중앙사고수습본부, 중앙방역대책본부


공정 변수 비교

- 변수 간 관계 분석
- 예시
 - 온도 ↔ 압력
 - 압력 ↔ 생산량
 - 진동 ↔ 설비 상태
- 확인할 수 있는 내용
 - 양의 관계
 - 음의 관계
 - 관계 없음
- 활용 그래프
 - 산점도(Scatter Plot)



품질과 공정 변수 비교

- 분석 목적
 - 어떤 공정 변수가 품질에 영향을 주는지 확인
- 예시
 - 온도 증가 → 불량률 증가
 - 압력 감소 → 생산량 감소
 - 진동 증가 → 설비 고장 발생
- 기대 효과
 - 품질 개선
 - 공정 최적화




음의 상관관계가
강하다.

음의 상관관계가
있기는 하다.

상관관계가 없다.

양의 상관관계가
있기는 하다.

양의 상관관계가
강하다.



시계열 패턴 분석

- 제조 데이터의 특징
 - 대부분 시간 정보를 포함
 - 시간에 따라 변화
- 확인 가능한 패턴
 - 증가 추세
 - 감소 추세
 - 반복 패턴
 - 급격한 변화
- 활용
 - 설비 이상 탐지
 - 품질 변화 분석

패턴 발견 예시

- 온도 데이터
 - 정상 구간에서는 일정 수준 유지
 - 특정 시점에서 급격히 증가
- 가능한 원인
 - 설비 이상
 - 센서 오류
 - 공정 조건 변화
- 핵심
 - 패턴은 문제의 단서가 됨

인사이트 도출

- 데이터
 - 온도 45°C
- 정보
 - 평균보다 높음
- 인사이트
 - 온도 45°C 이상에서 불량률 증가
- 인사이트의 특징
 - 원인 파악 가능
 - 의사결정 가능
 - 개선 방향 제시 가능

제조 데이터 분석 사례

- 분석 결과
 - 온도 상승 시 불량률 증가
 - 특정 설비에서 진동 증가
 - 야간 생산 시 품질 저하
- 개선 조치
 - 공정 온도 조정
 - 설비 점검
 - 작업 조건 개선
- 결과
 - 품질 향상
 - 불량 감소
 - 생산성 향상

정리 – 데이터 탐색

- 데이터 탐색의 목적
 - 데이터 이해
 - 패턴 발견
 - 변수 관계 분석
 - 인사이트 도출
- 기억해야 할 점
 - 그래프를 그리는 것이 목적이 아님
 - 의미 있는 패턴을 찾는 것이 중요
 - 인사이트는 의사결정으로 이어져야 함

→ 데이터 탐색은 데이터를 정보와 인사이트로 변환하는 과정이다

AI(인공지능)의 시대



AI의 정의

- AI는 인간의 지능을 컴퓨터로 구현하려는 기술의 집합
- 인간의 지능적 능력 예시
 - 학습하기 (경험으로부터 개선)
 - 인식하기(보기, 듣기)
 - 이해하기 (의미 파악)
 - 판단하기 (선택, 결정)

AI의 역사

1956년: AI의 탄생

다트머스 워크숍을 통해 AI가 하나의 학문 분야로 정립됨.

1980년대: 전문가 시스템

지식 기반 시스템이 특정 분야에서 인간 전문가 수준의 추론을 모사함.

2012년: 딥러닝의 도약

GPU 가속을 통해 심층 신경망에서 획기적인 성과가 나타남.

2022년-: 생성형 AI의 확산

대규모 트랜스포머 모델을 기반으로 ChatGPT와 같은 생성형 AI가 등장함.

AI는 하나의 기술이 아니다


- AI는 여러 기술의 집합
- 대표적인 구성 요소
 - 머신러닝/딥러닝
 - 컴퓨터 비전
 - 음성 인식
 - 자연어 처리

AI는 이미 우리 주변에 가득하다

- 스마트폰 얼굴 인식 → 컴퓨터 비전
- 음성 비서(시리, 빅스비) → 음성 인
- 파파고 번역기 → 자연어 처리
- "GPT야 내가 업로드한 이미지를 지브리 스타일로 바꿔 줘" → 자연어 처리 + 컴퓨터 비전
- 테슬라, 현대차의 휴머노이드 로봇 → 컴퓨터 비전 + 로봇



AI, 머신러닝, 딥러닝의 관계



과거의 AI: 규칙 기반 시스템

- 사람이 직접 규칙을 설계
- 예시
 - 만약 A이면, 행동 C
 - 만약 B이면, 행동 D
- 한계
 - 복잡한 문제를 풀기 위해서는 수많은 규칙이 필요하고 이를 사람이 모두 설계해야 함
 - 규칙이 많아질 수록 관리 불가능
 - 새로운 상황에 약함

전환점: 머신러닝의 등장

- 머신러닝: 컴퓨터가 데이터로부터 스스로 배우는 인공지능의 한 부분
- 규칙을 사람이 만들지 않음
- 기본 구조
 - 입력 데이터 → 학습 → 예측/판단
- 예시
 - 목표: 고양이 사진을 구분하기
 - 다른 동물들 사진과 고양이 사진 수천 장을 입력하여 컴퓨터가 고양이의 특징을 스스로 학습

신경망(Neural Network)이란?

- 신경망: 인간의 뇌 구조에서 아이디어를 차용한 수학적 계산 모델
- 여러 단계를 거쳐 결과를 출력
- 입력층, 은닉층, 출력층으로 구성



Image Credit: ExtremeTech




Image Credit: IBM

딥러닝은 무엇이 다른가?

- 딥러닝(Deep Learning): 여러 층의 신경망을 이용하는 머신러닝의 한 방법
- 이미지·음성·언어와 같은 복잡한 데이터에 강함
- 왜 Deep인가?
 - 여러 층을 거치면서 단순한 패턴 → 복잡한 개념을 점진적으로 학습
 - 예: 선 → 모양 → 사물 → 의미

딥러닝이 가능해진 배경

- 딥러닝 자체는 새로운 아이디어가 아니다
- 3가지 핵심 요소
 - 데이터: 인터넷, 센서, 로그 데이터의 폭발적 증가
 - 연산 능력: GPU, 대규모 병렬 연산
 - 알고리즘: 딥러닝 구조와 학습 기법의 발전
- 세 요소의 시너지로 딥러닝 발전 본격화



데이
터




연산 능력



알고리즘


MLP란?

- Multi-Layer Perceptron(다층 퍼셉트론)
- 특징
 - 여러 개의 층(Layer)으로 구성
 - 입력 데이터로부터 패턴 학습
 - 분류와 회귀 모두 가능




입력층(Input Layer)

- 역할
 - 데이터를 입력받음
- 예시
 - 온도, 압력, 진동, 전류
 - [35, 1.5, 0.02, 20]
- 핵심
 - 입력층의 노드 수 = 변수 수




은닉층(Input Layer)

- 역할
 - 입력 변수들의 관계를 학습
- 특징
 - 비선형 관계 학습
 - 복잡한 패턴 학습
- 핵심
 - 은닉층이 많을수록 더 복잡한 패턴 학습 가능




출력층(Input Layer)

- 분류 문제
 - 정상/불량 $\rightarrow$ 0 또는 1 (이진 분류)
 - 일반적으로 출력층 노드의 수는 클래스의 개수와 같게
- 회귀 문제
 - 수율(Yield)
 - 95.3%




퍼셉트론

- 신경망의 기본 단위는 뉴런 또는 퍼셉트론이라고 불린다




$$y = a\left(\sum_{k=1}^N w_k x_k + b\right)$$

단순화



MLP

- MLP는 뉴런들로 구성된 다수의 층들로 구성이 된다
- MLP에서, 이웃한 층 사이에 위치한 뉴런은 뻗뻗하게 연결되어 있다



MLP 학습 과정

- Step 1: 데이터 입력
- Step 2: 예측 수행
- Step 3: 실제 값과 비교
- Step 4: 오차 계산
- Step 5: 가중치 업데이트
- 위 과정을 반복
- 오차를 줄이는 방향으로 학습

MLP의 장점과 한계



- 장점
 - 구현이 간단
 - 다양한 데이터 적용 가능
 - 비선형 관계 학습 가능
- 한계
 - 데이터가 많아야 함
 - 해석이 어려움
 - 시계열 구조 반영 어려움
- 제조 데이터에서 널리 사용됨
 - 품질 예측
 - 불량 분류
 - 수율 예측

XGBoost

- 제조 데이터의 특징
 - 표(Table) 형태 데이터
 - 변수 수가 많음
 - 결측치 존재
 - 비선형 관계 존재
- XGBoost는 표 형식 데이터 분석에 매우 강력하다

트리 기반 모델

- 트리 기반 모델(Tree-based Model)은 데이터를 반복적으로 분할(split)하면서 예측을 수행
- 각 노드(node)에서 모델은 특정 변수(feature)와 임계값(threshold)을 선택하여 데이터를 두 개의 그룹으로 나눔
- 이 과정의 목표는 가능한 한 동일한 특성을 가진 데이터들로 구성된 순수한(pure) 그룹을 만드는 것
- 여러 번의 분할을 조합함으로써, 트리 기반 모델은 데이터에 존재하는 복잡하고 비선형적인 관계까지 학습 가능




단일 트리기반 모델의 한계

- 하나의 트리만 사용하면
 - 예측 성능 제한
 - 데이터 변화에 민감
- 해결 방법
 - 여러 개의 트리를 함께 사용 → 앙상블(Ensemble)
- 여러 모델을 결합하면 더 정확해진다


XGBoost

- XGBoost는 트리를 순차적으로 생성하며, 새로운 트리는 이전 트리들이 만들어낸 오차를 보완하도록 학습된다. 즉, 각 트리는 남아 있는 예측 오차를 줄이기 위해 추가된다.
- 이와 같이 여러 개의 약한 학습기(Weak Learner)를 결합함으로써, XGBoost는 높은 예측 성능을 갖는 강력한 모델을 구축할 수 있다.



XGBoost

- XGBoost는 여러 개의 트리가 생성한 예측 결과를 가중합(weighted sum)하여 최종 예측을 수행한다.
- 즉, XGBoost는 성능이 약한 여러 개의 트리(Weak Trees)를 결합하여 높은 예측 성능을 갖는 강력한 모델(Strong Model)로 만들어 준다.



변수 중요도(Feature Importance)

- **XGBoost의 장점**

- 어떤 변수가 중요한지 확인 가능

변수	중요도
온도	42%
압력	28%
진동	20%
전류	10%

- 해석

- 온도가 품질에 가장 큰 영향
- 제조 현장에서 매우 유용

MLP vs XGBoost


항목	MLP	XGBoost
데이터 양	많이 필요	상대적으로 적음
해석 가능성	낮음	높음
학습 속도	보통	빠름
표 형식 데이터	보통	매우 우수

- 많은 경우 XGBoost가 효과적이나 데이터셋 또는 상황에 따라 다름
→ 첫 시도로 XGBoost를 추천

실제 반도체 제조 데이터(SECOM) 분석 및 시각화

Step 0: 데이터와 관련된 사전지식 수집 및 종합

- SECOM Dataset:
 - 실제 반도체 공정 데이터
 - 각 샘플은 칩에 대응되고, 레이블은 -1이 정상, +1이 불량을 의미
 - 센서 의미 및 특성 이름 전부 익명화



실제 반도체 제조 데이터(SECOM) 분석 및 시각화

Step 1: 데이터 파악

- 데이터를 먼저 파악해야 한다 (직접 보기)

- 샘플 수, 특성 수, 범주형 특성 포함 여부, 레이블 분포, 결측치 포함 여부, 스케일, 불균형 등

- 전처리, 모델, 학습 전략 등을 결정

실제 반도체 제조 데이터(SECOM) 분석 및 시각화

Step 1: 데이터 파악

- 데이터를 먼저 파악해야 한다 (직접 보기)

- 샘플 수, 특성 수, 범주형 특성 포함 여부, 레이블 분포, 결측치 포함 여부, 스케일, 불균형 등

- 전처리, 모델, 학습 전략 등을 결정

```
X shape: (1567, 590)
y shape: (1567, 2)
```

실제 반도체 제조 데이터(SECOM) 분석 및 시각화

Step 1: 데이터 파악

- 데이터를 먼저 파악해야 한다 (직접 보기)

➤ 샘플 수, 특성 수, 범주형 특성 포함 여부, 레이블 분포, 결측치 포함 여부, 스케일, 불균형 등

→ 전처리, 모델, 학습 전략 등을 결정

SECOM Data Head:																					
	0	1	2	3	4	5	6	7	8	9	...	580	581	582	583	584	585	586	587	588	589
0	3030.93	2564.00	2187.7333	1411.1265	1.3602	100.0	97.6133	0.1242	1.5005	0.0162	...	NaN	NaN	0.5005	0.0118	0.0035	2.3630	NaN	NaN	NaN	NaN
1	3095.78	2465.14	2230.4222	1463.6606	0.8294	100.0	102.3433	0.1247	1.4966	-0.0005	...	0.0060	208.2045	0.5019	0.0223	0.0055	4.4447	0.0096	0.0201	0.0060	208.2045
2	2932.61	2559.94	2186.4111	1698.0172	1.5102	100.0	95.4878	0.1241	1.4436	0.0041	...	0.0148	82.8602	0.4958	0.0157	0.0039	3.1745	0.0584	0.0484	0.0148	82.8602
3	2988.72	2479.90	2199.0333	909.7926	1.3204	100.0	104.2367	0.1217	1.4882	-0.0124	...	0.0044	73.8432	0.4990	0.0103	0.0025	2.0544	0.0202	0.0149	0.0044	73.8432
4	3032.24	2502.87	2233.3667	1326.5200	1.5334	100.0	100.3967	0.1235	1.5031	-0.0031	...	NaN	NaN	0.4800	0.4766	0.1045	99.3032	0.0202	0.0149	0.0044	73.8432

5 rows × 590 columns

실제 반도체 제조 데이터(SECOM) 분석 및 시각화

Step 1: 데이터 파악

- 데이터를 먼저 파악해야 한다 (직접 보기)

➤ 샘플 수, 특성 수, 범주형 특성 포함 여부, 레이블 분포, 결측치 포함 여부, 스케일, 불균형 등

→ 전처리, 모델, 학습 전략 등을 결정

SECOM Labels Head:

	0	1
0	-1	19/07/2008 11:55:00
1	-1	19/07/2008 12:32:00
2	1	19/07/2008 13:17:00
3	-1	19/07/2008 14:43:00
4	-1	19/07/2008 15:22:00

Label distribution

	count
0	
0	1463
1	104

실제 반도체 제조 데이터(SECOM) 분석 및 시각화

Step 1: 데이터 파악



- 데이터를 먼저 파악해야 한다 (직접 보기)

➤ 샘플 수, 특성 수, 범주형 특성 포함 여부, 레이블 분포, 결측치 포함 여부, 스케일, 불균형 등

→ 전처리, 모델, 학습 전략 등을 결정

Missingness summary:

- Avg missing % per feature: 4.54
- Max missing % among features: 91.19
- Avg missing % per sample: 4.54



실제 반도체 제조 데이터(SECOM) 분석 및 시각화

Step 2: 데이터 전처리

- 모델이 학습하기에 최적의 형태로 전처리한다
 - 결측 데이터 처리
 - 상수 값 센서 제거
 - 스케일 정규화:
센서의 단위 차이로 인한 왜곡 방지
 - 레이블 전처리

	0	1	2	3	4	5	6	7	8	9	...	444	445	446	447	448	449	450	451	452	453
0	3.039879	-0.045288	2.244295	1.506984	-0.040017	0.0	-0.994377	-0.022772	-0.629128	0.229120	...	-0.273723	0.495806	-0.269042	-0.169280	-0.192617	-0.163382	0.464848	-0.020212	0.042184	-0.430597
1	-1.717727	-2.068365	0.579932	-1.096787	-0.044093	0.0	0.611948	-0.066681	0.637377	-0.078191	...	2.881145	-0.245756	0.132158	-0.040166	-0.002117	-0.038876	0.638893	-0.544648	-0.472790	-0.632861
2	0.385878	0.300827	0.076429	-0.457332	-0.045023	0.0	-0.194636	-0.209385	1.993569	-2.118216	...	-0.211869	-0.387961	-0.412328	-0.206169	-0.129117	-0.197813	-0.136400	0.516144	0.336455	0.050655
3	-0.280376	0.070629	0.616634	0.305634	-0.055606	0.0	0.734396	-0.132544	-0.033925	0.811050	...	-0.222352	-0.585996	0.476044	-0.141612	-0.129117	-0.139781	-1.125295	-0.592324	-0.399222	0.565026
4	-0.994117	0.198377	-0.923523	0.982295	-0.045384	0.0	-0.305179	0.635862	-0.786761	-0.424734	...	-0.267908	0.067029	0.705301	-0.284559	-0.256117	-0.274784	0.290802	-0.198997	-0.288871	-0.440541

실제 반도체 제조 데이터(SECOM) 분석 및 시각화

Step 3: 모델 학습



- 문제 정의에 기반한 모델 설계
- 문제·데이터 특성을 고려한 모델 선택
- 문제에 맞는 하이퍼파라미터 설정
- 분석 및 시각화 단계에서는,
모델을 예측 목적이 아닌 분석과 해석을 위한 도구로 활용

실제 반도체 제조 데이터(SECOM) 분석 및 시각화

Step 4: 학습 모델 기반 데이터 분석 및 시각화

3-1) 로지스틱 회귀 기반 분석

	feature_index	coef	abs_coef
0	59	1.484208	1.484208
1	132	-1.216246	1.216246
2	75	1.077832	1.077832
3	425	1.029341	1.029341
4	22	-1.014570	1.014570
5	21	0.913368	0.913368
6	214	-0.876928	0.876928
7	14	-0.847468	0.847468
8	563	-0.846857	0.846857
9	64	0.836820	0.836820
10	164	-0.794316	0.794316
11	17	0.771753	0.771753
12	168	0.747191	0.747191
13	56	0.735994	0.735994
14	78	-0.704852	0.704852




실제 반도체 제조 데이터(SECOM) 분석 및 시각화

Step 4: 학습 모델 기반 데이터 분석 및 시각화

3-2) XGBoost 기반 분석



	feature	gain	weight	cover	feature_name
104	f200	11.436420	1.0	9.335733	221
359	f62	9.223208	13.0	25.598907	64
115	f210	8.698730	2.0	5.266936	248
396	f99	7.842897	30.0	23.059208	103
27	f125	6.781818	4.0	22.845388	132
128	f224	6.621907	4.0	6.759667	273
342	f452	6.601439	3.0	7.858070	588
241	f343	6.572530	4.0	30.488834	435
123	f22	6.323678	1.0	2.341069	23
246	f35	6.285871	1.0	18.959249	36
345	f47	6.094902	4.0	15.657741	48
289	f393	6.049773	7.0	11.705941	497
302	f409	5.739344	7.0	12.116969	541
62	f159	5.714236	1.0	11.836249	170
36	f133	5.656317	2.0	5.560884	140
15	f114	5.575050	4.0	20.032951	121
158	f26	5.534302	10.0	14.730078	27
360	f63	5.338709	6.0	15.290832	65
10	f11	5.166126	6.0	13.005517	11
18	f117	4.975808	4.0	16.513458	124



실제 반도체 제조 데이터(SECOM) 분석 및 시각화

Step 4: 학습 모델 기반 데이터 분석 및 시각화



3-3) SHAP 분석



실제 반도체 제조 데이터(SECOM) 분석 및 시각화

Step 4: 학습 모델 기반 데이터 분석 및 시각화

3-3) SHAP 분석



정리

- 제조 데이터 분석은 문제 정의에서 시작
- 문제 정의 후 다음 순서로 진행
사전지식 종합 → 데이터 파악 → 전처리 → 모델 학습 → 데이터 분석 및 시각화
- 데이터 분석 및 시각화 결과를 통해,
공정 개선을 위한 인사이트 도출
- 최종 의사결정은 도메인 지식 및 현장 경험과 결합되어야 함

Design of Experiments (DOE)

- 실험계획법
 - Design of Experiments
 - 제조 공정 최적화를 위한 대표적인 방법
 - 적은 실험으로 중요한 요인 파악
 - 품질 향상 및 수율 최적화에 활용
- 활용 분야
 - 반도체
 - 배터리
 - 화학공정
 - 자동차 제조

왜 DOE가 필요할까?

- 수율에 영향을 주는 변수: 온도, 압력, 속도
- 질문
 - 어떤 변수가 가장 중요할까?
 - 어떤 조건이 최적일까?
- 모든 조합을 실험한다면?

온도	3 수준
압력	3 수준
속도	3 수준

- 총 실험 수: $3 \times 3 \times 3 = 27$
- 문제: 시간 증가, 비용 증가

DOE 기본 개념

- **Factor**

- 실험 변수
- 예시: 온도, 압력, 속도

- **Level**

- 변수의 설정값
- 예시: 온도 → 낮음, 높음

- **Response**

- 실험 결과
- 예시
 - 수율
 - 불량률
 - 생산량

DOE 결과 분석 및 공정 최적화

온도	압력	수율
Low	Low	85
Low	High	87
High	Low	95
High	High	96

- 관찰:
 - 온도 증가 → 수율 크게 증가
 - 압력 증가 → 수율 소폭 증가
- 결론: 온도가 더 중요한 변수
- 최적 조건: 온도 = High, 압력: High

DOE의 장점과 한계

- 장점: 높은 해석성
- 변수 수 증가
 - 예시
 - 5개 변수이면 2수준 DOE의 경우 $\rightarrow 2^5 = 32$ 번의 실험 필요
 - 10개 변수이면 2수준 DOE의 경우 $\rightarrow 2^{10} = 1024$ 번의 실험 필요
- 문제
 - 실험 비용 증가

베이지안 최적화(Bayesian Optimization)

- 왜 필요한가?
 - 수율을 높이기 위해서는 온도, 압력, 속도 등의 공정 조건을 최적화해야 함
- 문제
 - 실제 실험은 비싸고 시간이 오래 걸림
- 목표
 - 적은 실험으로 최적 조건 찾기
- 핵심
 - 베이지안 최적화는 다음에 어떤 실험을 수행할지 추천하는 방법이다.

베이지안 최적화의 아이디어

- **Step 1:** 몇 개의 초기 실험 수행
- **Step 2:** 실험 결과로 수율 예측 모델 생성
- **Step 3:** 가장 유망한 조건 추천
- **Step 4:** 실험 수행 후 모델 업데이트
- 위 과정을 반복
 - 좋은 조건을 찾으면서도, 새로운 조건도 탐색한다.

DOE와 베이지안 최적화

DOE	베이지안 최적화
미리 실험 계획 수립	결과를 보며 실험 추천
고정된 실험 설계	적응적 실험 설계
변수 많아지면 비효율	적은 실험으로 최적화 가능

- 베이지안 최적화는 적은 실험으로 높은 수율을 달성하기 위한 최신 공정 최적화 기법이다.
- 베이지안 최적화는 수율 최적화에 사용되기에 매우 적합한 방법
- 더 적은 비용으로 최적의 공정 조건을 찾을 수 있다